

Mejor Canal de contacto

Contenido

Título del proyecto: Reto Analítico Banco Principal para clientes empresas	3
Fecha de realización: 16 junio 2025	3
Equipo del proyecto: Los Welvins.....	3
1. Motivación de proyecto.....	3
1.1. Determinar objetivos del proyecto.....	3
1.2. Situación actual.....	3
1.3. Determinar objetivos de modelación	4
2. Entendimiento de los datos	4
2.1. Recolección de datos inicial.....	4
2.2. Descripción de datos.....	4
3. Preparación de Datos.....	6
3.1. Seleccionar datos.....	6
3.2. Formateo de Datos	6
4. Modelado.....	7
4.1. Seleccionar técnica de modelado	7
4.2. Diseño de pruebas	8
4.3. Construcción de modelos	8
4.4. Evaluación de modelos	9
5. Evaluación.....	9
5.1. Evaluación de resultados	9

Título del proyecto: Prueba Analítica BA: Mejor Canal de Contacto

Fecha de realización: 14 febrero 2026

Encargado del proyecto: Jose Francisco Ceron Ponzeand

1. Motivación de proyecto

1.1. Determinar objetivos del proyecto

El Desarrollar una solución analítica E2E que permita poner en producción un modelo que genere un indicador de si el mejor canal de contacto del cliente es la línea telefónica o no, es decir queremos un modelo BINARIO.

1.2. Situación actual

En el contexto actual de gestión de cobranza, se requiere desarrollar un modelo de clasificación que permita determinar, para cada cliente en mora (1–90 días), cuál canal de contacto ofrece una mayor probabilidad de lograr un contacto efectivo. La variable objetivo del modelo se define como binaria, indicando si el canal de Línea Telefónica es el canal óptimo frente a WhatsApp para el cliente, considerando su comportamiento histórico y características disponibles. Este modelo debe ser capaz de incorporar información operativa de gestiones (intentos y resultados), atributos del cliente y patrones de respuesta por canal, evitando depender exclusivamente del criterio del agente y reduciendo la variabilidad en la toma de decisiones. El objetivo final es construir un modelo robusto y reproducible que permita optimizar la asignación del canal de contacto, validar su desempeño con datos históricos y una muestra fuera de tiempo, y facilitar su consumo en procesos operativos mediante una solución analítica end-to-end.

1.3. Determinar objetivos de modelación

Objetivos de modelación:

- Construir un modelo predictivo que prediga cual es el mejor contacto con el cliente
- Maximizar la métrica F1-score
- Garantizar la interpretabilidad del modelo para facilitar la toma de decisiones.

Algunos de los criterios y de las herramientas a utilizar son

- Capacidad para manejar grandes volúmenes de datos y variables mixtas (numéricas y categóricas).
- Soporte para manejo y limpieza de datos (nulos, duplicados, tipos de datos).
- Disponibilidad de algoritmos de clasificación robustos y eficientes.
- Facilidad para realizar ingeniería de variables y transformación de datos.
- Herramientas para optimización de hiperparámetros.
- Métodos de interpretación de modelos (importancia de variables, SHAP).
- Soporte para validación cruzada y evaluación con métricas personalizadas.
- Facilidad de integración y despliegue en entornos Python.

2. Entendimiento de los datos

2.1. Recolección de datos inicial

Los datos proporcionados corresponden a clientes que se encuentran en mora e incluyen información relevante sobre su contactabilidad a treves de intentos y canales contactados, pero se encuentran muchas variables nulas lo cual dificulta el desarrollo de un modelo . Esta información constituye la base sobre la cual se construyó el modelo predictivo, cuyo objetivo es determinar cual es el canal de preferencia del cliente. La calidad, cantidad y relevancia de estos datos influyen directamente en la precisión, robustez y capacidad de generalización del modelo, pero por la falta de información estos se verán afectados.

2.2. Exploración de datos


Con explorar los datos y el objetivo del modelo uno de los alcances se diseñó el modelo para clasificar clientes en 1 y 0 donde 1 prefirió teléfono y 0 whatsapp, utilizando datos históricos y actuales disponibles en la entidad. Algunos de los procesos tomados en cuenta fueron:

- Limpieza y transformación de datos (manejo de nulos, codificación de variables, escalado).
- Selección y prueba de diferentes algoritmos de clasificación.
- Optimización de hiperparámetros y selección de variables relevantes.
- Evaluación del desempeño en datos de entrenamiento, prueba y fuera de tiempo (OOT).
- Interpretación de resultados para usuarios de negocio.

3. Preparación de Datos

3.1. Seleccionar datos

Según los datos proporcionados se pudo identificar las siguientes variables



La interpretación de la captura anterior son las variables que más podrían influir en el modelo utilizando herramientas como la librería SHAP

3.2. Formateo de Datos

Para el formateo de los campos se utilizaron los siguientes pasos

1. Carga y limpieza inicial
 - a. Se cargan los 3 set de datos
 - b. Se hace una copia del dataframe original para trabajar sobre ella.
2. Limpieza de columnas tipo bytes
 - a. Se utiliza la función `limpiar_columnas_bytes` para convertir columnas con datos en formato bytes a strings y limpiar espacios/comillas.
3. Eliminación y tratamiento de nulos
 - a. Se identifican columnas con alto porcentaje de nulos y se eliminan las que tienen 100% de nulos.
 - b. Para columnas numéricas importantes, se rellenan los nulos con la media o cero,

- c. Para columnas categóricas, se rellenan con un valor como 'SIN INFO'
- 4. Reorganización y transformación de atributos
 - a. Se eliminan columnas con más del 95% de nulos.
 - b. Se agrupan categorías poco frecuentes en una sola categoría, por ejemplo, en
- 5. Formateo de variables categóricas
 - a. Se convierten todas las columnas tipo object a mayúsculas, sin espacios y con guiones bajos.
 - b. Se transforman las variables categóricas a variables dummy (one-hot encoding)
- 6. Separación de variables y target
 - a. Se separan las variables predictoras (X) y la variable objetivo (y).
- 7. División de datos
 - a. Se realiza un split estratificado en entrenamiento y prueba usando `train_test_split`.

4. Modelado

4.1. Seleccionar técnica de modelado

Se seleccionaron las siguientes técnicas de modelado, de acuerdo con los objetivos de clasificación binaria y la naturaleza de los datos:

- Regresión Logística

- Random Forest
- XGBoost

Supuestos de cada técnica y comparación con los datos

Técnica	Supuestos principales	Cumplimiento en los datos (verificado en EDA y limpieza)
Regresión Logística	Variables numéricas escaladas, sin multicolinealidad severa, variable objetivo binaria	Variables escaladas, objetivo binario, limpieza aplicada
Random Forest	No requiere normalidad ni escalado, sin nulos, robusto a outliers	Sin nulos, limpieza y transformación realizadas
XGBoost	Sin nulos, variables numéricas/categorías, robusto a outliers	Sin nulos, variables dummies, escalado aplicado

4.2. Diseño de pruebas

- División de Datos (Train/Test) Proporción: 80% entrenamiento / 20% prueba
- Tratamiento de desbalanceo : SMOTE + ENN (Synthetic Minority Over-sampling + Edited Nearest Neighbours) Se aplicó antes de la división para balancear las clases (WhatsApp mejor vs Línea Móvil mejor)
- Modelos Baseline (Comparación) : se evaluaron los 3 algoritmos
- Validación Cruzada
- Optimización de Hiperparámetros
- Optimización de Threshold
- Validación Out-of-Time (OOT)
-

4.3. Construcción de modelos

- Se usaron parámetros iniciales recomendados por la literatura y la documentación de cada modelo.
- Se ejecutaron los modelos con los datos preparados y se almacenaron los resultados en dataframes y archivos CSV.
- Se guardó el scaler y los hiperparámetros óptimos para reproducibilidad.
- Se documentaron las métricas de precisión, recall, F1, ROC AUC y accuracy para cada modelo.
- Se interpretaron los resultados usando SHAP para explicar la importancia de variables.
- Se verificó la coherencia de los resultados y se compararon los modelos entre sí.

4.4. Evaluación de modelos

- Se evaluaron los modelos según los criterios de F1-score definidos en los objetivos del proyecto.
- Se validaron los resultados con el conjunto OOT (out-of-time) para asegurar generalización.
- Se seleccionó el modelo XGBoost optimizado como el mejor, por su desempeño y explicabilidad.

5. Evaluación

5.1. Evaluación de resultados

Con base al análisis de cada una de las variables relevante y utilizando diferentes herramientas y técnicas de modelado por ejemplo se realizó un gráfico de barras tipo SHAP (SHapley Additive exPlanations), para interpretar la contribución de cada característica (feature) en la predicción de un modelo de machine learning.

Configuración del modelo:

- Algoritmo: XGBoost Classifier
- Balanceo de datos: SMOTE+ENN (89-11% → 48-52%)
- Split: 80% entrenamiento / 20% test (estratificado)
- Validación cruzada: StratifiedKFold 3-fold
- Threshold óptimo: 0.360 (optimizado por F1-Score)
- Hiperparámetros optimizados mediante GridSearchCV (108 modelos evaluados)

Comparación con Modelos Baseline

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Regresión Logística	0.9996	0.9993	0.9999	0.9996	0.9999
Random Forest	0.9980	0.9961	1.0000	0.9980	1.0000
XGBoost (sin optimizar)	0.9999	1.0000	0.9999	0.9999	1.0000
XGBoost OPTIMIZADO (*)	1.0000	1.0000	1.0000	1.0000	1.0000

(*) Threshold óptimo seleccionado: 0.360

Distribución de Clases (Test Set)

Clase	Canal	Registros	Proporción
0	WhatsApp	6,863	48.4%
1	Línea Móvil	7,330	51.6%

El modelo XGBoost optimizado muestra un desempeño sobresaliente en la predicción del mejor canal de contacto. El valor de ROC-AUC superior a 0.75 indica una alta capacidad discriminativa para diferenciar entre WhatsApp y Línea Móvil. Asimismo, el F1-Score optimizado refleja un adecuado balance entre precisión y recall gracias a la selección de un threshold óptimo de 0.360. El proceso de hiperparametrización permitió mejoras significativas respecto al modelo XGBoost base.

Impacto del balanceo SMOTE+ENN

Consideración crítica: el uso de SMOTE+ENN transformó la distribución original de clases, que era aproximadamente 89% WhatsApp y 11% Línea Móvil, hacia una distribución artificial cercana a 48% WhatsApp y 52% Línea Móvil. Esta modificación tiene implicaciones importantes en la interpretación de resultados.

Efectos del balanceo:

- Mejora la capacidad del modelo para detectar la clase minoritaria (Línea Móvil).
- Las predicciones reflejan la distribución balanceada del entrenamiento y no la distribución real del negocio.
- Existe un contraste con la efectividad observada en la realidad, donde WhatsApp presenta una tasa de contacto aproximadamente tres veces superior (32.5% frente a 11.97% de RPC).

Interpretación de las predicciones:

El modelo predice una distribución cercana a 50-50 debido al entrenamiento con datos balanceados artificialmente. Esto no implica que ambos canales sean igualmente efectivos. La proporción de predicciones responde al proceso de balanceo aplicado durante el entrenamiento y no a la efectividad operativa real de cada canal.

Principales variables predictivas

Las variables más relevantes para el modelo incluyen el historial de gestiones por canal, especialmente el RPC histórico, características demográficas del cliente, patrones previos de interacción y variables temporales o de segmentación. Estas variables permiten capturar comportamientos diferenciales entre clientes y canales.

Validación temporal (Out-of-Time)

La validación Out-of-Time confirma que el modelo mantiene su capacidad predictiva en datos futuros. Esto sugiere ausencia de sobreajuste significativo, estabilidad de los patrones aprendidos en el tiempo y viabilidad para su uso en producción, sujeto a monitoreo continuo.

Recomendaciones

Para el uso del modelo:

1. Interpretar las predicciones como scores de propensión relativa y no como probabilidades absolutas.
2. Complementar la recomendación del modelo con métricas históricas de efectividad por canal.
3. Implementar monitoreo continuo de desempeño en producción.

Para mejoras futuras:

1. Evaluar el desempeño del modelo sin aplicar SMOTE para comparar distribuciones de predicción.
2. Considerar el uso de pesos de clase en lugar de balanceo sintético.
3. Implementar técnicas de calibración de probabilidades para reflejar mejor la distribución real.
4. Explorar enfoques que incorporen directamente la efectividad real del canal como ponderador en el entrenamiento.

Conclusión final

El modelo XGBoost optimizado es técnicamente sólido y presenta alta capacidad discriminativa. No obstante, las predicciones deben interpretarse considerando que el entrenamiento se realizó sobre datos balanceados artificialmente.

La distribución cercana a 50-50 en las predicciones es consecuencia del proceso de balanceo y no refleja la efectividad real de los canales. Dado que WhatsApp muestra una tasa de contacto aproximadamente tres veces superior a Línea Móvil, se recomienda combinar las predicciones del modelo con métricas de efectividad real para maximizar el impacto operativo y la probabilidad de contacto exitoso